FICHE 24 – INTELLIGENCE ARTICIFICIELLE : CONCEPTION ET APPRENTISSAGE

Se doter des ressources et outils nécessaires pour développer un système d'IA robuste, fiable et performant.

Qu'il s'agisse de l'entraînement d'un nouveau modèle ou de l'intégration d'un modèle existant dans un logiciel ou un écosystème d'applications, le développement d'un système d'intelligence artificielle (IA) nécessite la mise en œuvre de certaines mesures de sécurité spécifiques. **Le volume important de données d'entraînement**, tout comme la **complexité de ces systèmes**, augmentent la surface d'attaque et le risque de défaillance pouvant avoir des conséquences graves **sur la fiabilité du système.** Cette fiche énumère plusieurs recommandations **d'ordre technique et organisationnel** permettant d'atteindre un premier niveau de sécurité.

Les précautions élémentaires

- Constituer une **équipe de développement aux compétences pluridisciplinaires** (analyse et ingénierie des données, interface et expérience utilisateur, contrôle qualité, administration des infrastructures informatiques, équipes métier), veiller à sa formation sur les bonnes pratiques de sécurité et sensibiliser aux vulnérabilités propres à l'IA.
- Mettre en œuvre une procédure obligatoire pour le développement et l'intégration continus, reposant sur des **tests exhaustifs et robustes, des accès soumis à habilitation et à une authentification adaptée aux profils** (voir la fiche n°4 - Authentifier les utilisateurs), notamment pour les modifications apportées au code de production (voir la fiche n°11 - Encadrer les développements informatiques).
- **Vérifier la qualité des données et des annotations, la présence possible de biais, la fiabilité des sources de données**, notamment afin d'éviter que les données ne puissent être manipulées par un tiers (ex. : empoisonnement).
- **Éviter les copies, partielles ou totales, des bases de données** et en restreindre l'accès et l'utilisation aux seules personnes habilitées pour des cas le nécessitant. **Recourir à des données fictives ou de synthèse** dans les autres cas, comme pour les tests de sécurité, l'intégration, ou pour certains audits.
- **Construire un recueil documentaire** à l'intention des développeurs et des utilisateurs du système, portant notamment sur :
  - la conception du système, et notamment les données et modèles utilisés ainsi que les analyses ayant conduit à leur sélection et à leur validation, et les résultats de ces analyses ;
  - le fonctionnement du système durant tout son cycle de vie, ses performances, l'analyse de ses biais et les résultats obtenus, ses conditions d'utilisations et limitations d'usage, comme les cas où la performance peut être insuffisante ;
  - les équipements matériels nécessaires pour l'utilisation du système, la latence attendue ou encore la capacité maximale pour les systèmes accessibles en SaaS.

126 Les attaques par inversion de modèle visent à reconstituer les données ayant servi pour l'apprentissage du système.